


광학 분자구조 인식 성능 향상을 위한 DDPM 기반의 분자 구조 생성 및 준지도학습 연구

김진혁, 송태웅, 최종환

한림대학교 소프트웨어학부

목차

1. 서론
2. 방법
3. 실험결과
4. 결론





- 

"CC1=CC(O)=C2CC=CCC2=C1O"

- OCSR은 문헌자료에 삽입되어 있는 분자구조 정보를 효과적으로 수집할 수 있는 도구
- 인식 정확도가 높은 OCSR 모델 개발은 화학정보학 및 AI응용 분야에서 중요한 과제


OCSR 대표사례: MolScribe¹



- **Image Encoder (swin transformer)**
 - 입력 이미지에 대한 특징벡터 계산
- **Graph Decoder (transformers)**
 - Image Encoder에서 나온 특징벡터를 기반으로 원자(atom)과 결합(bond)을 예측
 - Atom Predictor와 Bond Predictor를 이용하여 분자구조를 완성함


1. Qian, Yujie, et al. "MolScribe: robust molecular structure recognition with image-to-graph generation." *Journal of Chemical Information and Modeling* 63.7 (2023): 1925-1934.

기존 OCSR 모델의 한계점




분자구조 이미지 스타일(style)에 따른 파인튜닝(fine-tuning) 작업 필요

- MolScribe의 훈련데이터
 - PubChem (1m680k 정도의 대규모 데이터집합)
- PubChem을 학습한 모델을 이용하여 PubChem과 스타일이 다른 분자구조 이미지에 적용하면 인식 정확도가 높지 않음
- 아래의 예시는 ChemDraw 소프트웨어로 그린 분자구조 데이터에 대한 적용 예임




PubChem




ChemDraw

정답	<chem>CC1=CC(C#N)=C(NC2=CC=CC=C2[N+](=O)[O-])S1</chem>
예측	<chem>CC1SC(NC2C([N+])([O-])=O)=CC=CC=2)=C(C#N)C=1.CC1SC(NC2C([N+])([O-])=O)=CC=CC=2)=C(C#N)C=1</chem>

OCSR 파인튜닝의 어려움




- PubChem 데이터로 사전학습된 모델을 fine-tuning하는 전략



- 그런데, ChemDraw 스타일을 충분히 학습시키기 위해서는 많은 양의 데이터가 필요
 - ChemDraw의 5,704개 데이터로는 충분한 fine-tuning이 어려움


**다량의 훈련데이터 확보를 위해 DDPM을 활용한
데이터 증강(data augmentation) 기법을 제안**

분자구조 이미지 생성을 위한 DDPM



DDPM (Denoising Diffusion Probabilistic Model)



- Diffusion model 계열에 속하는 생성 모델(generative model)
- DDPM 학습 과정
 - ✓ Forward process: 고의적으로 패턴을 무너트리는 일
 - ✓ Reverse process: 무너진 패턴을 다시 복원하는 조건부 PDF(확률 밀도 함수)를 학습



<https://sushant-kumar.com/blog/ddpm-denoising-diffusion-probabilistic-models>

- DDPM 생성 과정: 임의의 노이즈(x_T)를 샘플링하여 reverse process만을 이용함

레이블 부여를 위한 Pseudo Labeling




OCSR을 훈련 시키기 위해서 '이미지'와 'label'이 필요

- DDPM은 이미지만 생성하며, 각 이미지에 대한 대응되는 label 정보가 부재함
- 문자열 쌍을 만들기 위한 pseudo-labeling 전략을 활용


Pseudo-labeling¹

- 레이블이 없는 데이터에 의사 레이블(pseudo label)을 부여하는 준지도학습(semi-supervised learning)알고리즘


- ① Labeled data로 사전학습을 수행
- ② 사전학습 모델로 unlabeled data의 label을 예측
- ③ Pseudo-labeled + Labeled data를 사용해 재학습




https://www.researchgate.net/figure/Schematic-diagram-of-pseudo-labeling_fig2_341813397



OCSR 파인튜닝이 어려운 작은 데이터집합을 효과적으로 학습하기 위한
DDPM + Pseudo Labeling 기반의 파인튜닝 전략을 제안



- ① **DDPM train**
 - ChemDraw 데이터로 DDPM 학습
- ② **DDPM sampling**
 - 분자구조 이미지 생성
- ③ **OCSR inference**
 - Pseudo-labeling 수행
- ④ **OCSR retrain**
 - ChemDraw + DDPM
 - Pretrained 모델 retrain



Method	Data size (for finetuning)	Tanimoto similarity
		ChemDraw
Pretrained	-	0.714
ChemDraw	4,163	0.847
ChemDraw +DDPM (ours)	14,728	0.901

➤ 인식 정확도 5.4%p 향상

- 모델 성능 비교


1. Pretrain된 모델
 2. ChemDraw
 3. ChemDraw + DDPM (ours)
- } baseline

- 교차검증 기반의 성능평가

- ChemDraw 데이터집합을 training & test로 분할
- Training dataset: 4,163개
- Test dataset: 500개

- 평가 지표 - 타니모토 유사도(Tanimoto Similarity)

- ✓ 정답 SMILES와 예측한 SMILES의 유사도 측정을 위해 사용
- ✓ 1에 가까울수록 모델이 정확하게 인식했다고 해석 가능



내용 요약


- OCSR 성능 향상을 위한 DDPM + Pseudo labeling 기반 학습 전략을 제안
- 제안 알고리즘으로 인식 정확도 5.4%p 향상시킬 수 있음을 확인

제안 알고리즘의 한계

- Label을 부여하는 모델이 잘 동작하지 않으면 pseudo-labeling 수행 불가
- 예를 들어, 손으로 그린 분자구조 이미지 데이터 셋인 DECIMER 데이터로는 pseudo-labeling 수행이 불가능

추후 연구

- Pseudo-labeling 기능 고도화 연구
- 더 다양한 OCSR 모델에 제안 알고리즘을 적용



DECIMER

정답:

[B]C(=S)[B]

예측:

C([Z])([G])=S

Q & A

감사합니다

APC Lab.
AI-Powered Cheminformatics Laboratory

